

文本表示如何影响新闻分类： 词袋模型、词向量与 BERT 的比较

唐健 2412103

密码与网络空间安全学院 密码科学与技术
自然语言处理实验一

摘要

本文比较六种文本分类方法在纽约时报新闻数据集上的表现，包括二值词袋、词频词袋、在两种新闻语料上训练的 Word2Vec、预训练 GloVe 和微调 BERT。实验使用相同的训练、验证和测试划分，并同时考察准确率与宏平均 F1。二值词袋取得最高的测试准确率 99.05% 和宏平均 F1 97.64%；在目标数据上训练的 Word2Vec 优于外部新闻语料版本，尽管 GloVe 拥有更高的词汇覆盖率。BERT 的准确率为 98.35%，宏平均 F1 为 96.27%。分析发现，体育新闻容易识别，而商业与政治新闻是主要的混淆来源。BERT 仅使用文章开头的短片段，词袋与静态词向量则处理全文，这也是理解结果差异的重要条件。实验表明，对于主题清晰的长新闻，简单的词汇特征依然是一种强有力的表示。

1 引言

一篇新闻的主题往往可以从几个关键词中判断。球队、联赛和球员指向体育报道；公司、市场和股价通常与商业有关。然而，当一篇报道同时涉及政府政策和企业经营时，仅凭关键词就不容易区分主题。不同的文本表示方法，恰好在这两类信息之间作出了不同选择。

词袋模型保留每个词是否出现或出现多少次，因此可以直接利用主题词。Word2Vec 和 GloVe 将单词表示为低维向量，使含义相近的词获得相近表示。BERT 进一步结合上下文确定词语含义 (Mikolov et al., 2013; Pennington et al., 2014; Devlin et al., 2019)。这些方法越来越复杂，却不意味着在每一项分类任务上都能依次获得更高的准确率。简单词汇特征在文本分类中的竞争力早已有研究指出 (Wang and Manning, 2012)。

本实验以 NYT 新闻三分类为例，回答三个具体问题：二值词袋和词频词袋是否存在明显差异；词向量的训练语料与词汇覆盖率如何影响分类；BERT 在输入长度受限时表现如何。除总体结果外，我们还比较各类别表现、混淆方

数据集	商业	政治	体育	总计
训练集	1,143	1,161	6,911	9,215
验证集	143	145	864	1,152
测试集	143	145	864	1,152
全部	1,429	1,451	8,639	11,519

表 1: NYT 新闻数据集的类别数量与划分。

向以及模型预测错误的文章，以解释数字背后的差异。

2 数据与实验设置

2.1 数据集与划分

NYT 数据集共有 11,519 篇有效新闻，包含商业、政治和体育三个类别。体育新闻占 75.0%，另外两类各占约 12.5%。这是一个明显不均衡的数据集，模型即使识别了大多数体育新闻，也可能在其他两类上表现欠佳。图 1 展示类别分布。

所有方法采用相同的分层随机划分。首先取 80% 数据作为训练集，再将其余 20% 平分为验证集和测试集，随机种子固定为 42。各集合的具体数量见表 1。另有 90,000 篇 AG News 文本，仅用于训练外部 Word2Vec，不参与 NYT 分类器的监督训练。

2.2 评价指标

我们使用准确率衡量整体预测的正确比例，并采用宏平均 F1 (Macro-F1) 衡量不同类别上的表现。对于类别 c ，F1 由真阳性、假阳性和假阴性计算，再对三个类别取平均：

$$\text{Acc} = \frac{1}{N} \sum_{i=1}^N \mathbf{1}(\hat{y}_i = y_i), \quad (1)$$

$$F_{1,c} = \frac{2TP_c}{2TP_c + FP_c + FN_c}, \quad (2)$$

$$\text{Macro-F1} = \frac{1}{3} \sum_{c=1}^3 F_{1,c}. \quad (3)$$

准确率容易受到体育这一多数类的影响，而 Macro-F1 给予三个类别相同权重。作为参照，




图 1: NYT 数据集的类别分布。左侧为各类别样本数，右侧为训练、验证和测试集中的类别比例。

方法	主要设置
词袋 + LR	60,980 维；迭代上限 2,000
Word2Vec	CBOW；100 维；窗口 5；最小词频 2；训练 10 轮
词向量 + LR	均值池化；迭代上限 3,000
BERT	bert-base-uncased；最大长度 64；训练 3 轮
优化器	AdamW；学习率 2×10^{-5} ；权重衰减 0.01

表 2: 三项任务的主要实验参数。LR 表示逻辑回归。

始终预测体育类可获得 75.00% 的准确率，但 Macro-F1 只有 28.57%。

2.3 训练配置

表 2 汇总关键配置。任务一和任务二均使用逻辑回归分类器；任务三微调整个 BERT 模型，并使用验证集 Macro-F1 选择最终模型。所有模型只在测试集上报告最终性能。

3 三类文本表示方法

3.1 Task 1: 词袋模型

词袋模型将文档表示为词表上的稀疏向量。设 $n(w, d)$ 表示单词 w 在文档 d 中出现的次数，则二值词袋和词频词袋分别定义为

$$x_w^{\text{binary}}(d) = \mathbf{1}[n(w, d) > 0], \quad (4)$$

$$x_w^{\text{freq}}(d) = n(w, d). \quad (5)$$

两种表示使用相同的 CountVectorizer 和逻辑回归分类器，差别只在于是否保留词的重复次数。词表仅由训练集建立，共包含 60,980 个特征。模型可以直接为 company、government 或 football 等词学习分类权重，但无法利用词序及词语的上下文含义。

3.2 Task 2: 静态词向量

我们比较三组 100 维词向量：在 NYT 训练集上训练的 Word2Vec、在 AG News 上训练的 Word2Vec，以及公开发布的 GloVe 6B 词向量。两组 Word2Vec 均采用 CBOW，窗口大小为 5，训练 10 轮。前两者可以比较目标语料与外部语料的差异；GloVe 则提供大规模预训练的参照 (Mikolov et al., 2013; Pennington et al., 2014)。

为将不同长度的新闻转换为固定维度的特征，我们对文档中的已知词向量取平均。设 $t_1, \dots, t_m$ 是文档中能在词向量表中找到的 m 个词位置，则

$$\mathbf{z}(d) = \frac{1}{m} \sum_{i=1}^m \mathbf{e}(t_i). \quad (6)$$

同一个词出现多次就参与多次平均；未收录的词不参与计算。若没有任何词被收录，则使用零向量。最后用逻辑回归完成分类。该方法能够利用单词之间的语义联系，却会丢失词序，也无法自动突出全文中最重要的主题词。

3.3 Task 3: BERT 微调

任务三使用 google-bert/bert-base-uncased，在预训练编码器上增加三分类输出层，并更新所有模型参数 (Devlin et al., 2019)。训练采用 AdamW，学习率为 2×10^{-5} ，批次大小为 8，前 10% 的训练步骤用于学习率预热。模型训练 3 轮，每轮结束后记录验证集结果，最终选择验证 Macro-F1 最高的检查点。

与前两项任务不同，BERT 的最大输入长度固定为 64。这个长度包含 [CLS] 和 [SEP] 等特殊标记，因此正文至多保留前 62 个 WordPiece。词袋模型与平均词向量使用全文，而 BERT 主要根据新闻开头判断类别。理解后续结果时，需要考虑这种输入范围的差别。

4 实验结果

4.1 总体表现

表 3 和图 2 给出了六种方法的结果。二值词袋在测试集上取得 99.05% 的准确率和 97.64% 的 Macro-F1，为本实验的最高值。词频词袋紧随其后，准确率为 98.96%，Macro-F1 为 97.42%。两者只相差一个预测正确的样本。这说明，对于当前新闻主题分类任务，词是否出现已包含大量判别信息，进一步记录出现次数并没有明显提高性能。

三种静态词向量也取得较高分。其中 NYT Word2Vec 的 Macro-F1 为 96.72%，GloVe 为 96.33%，AG Word2Vec 为 95.17%。BERT 的 Macro-F1 为 96.27%，接近 GloVe，但低于两个词袋模型。模型规模更大、结构更复杂，并未在当前实验设置下转化为更好的分类结果。

4.2 训练语料与词汇覆盖

NYT Word2Vec 比 AG Word2Vec 少错 8 篇新闻，Macro-F1 高出 1.55 个百分点。虽然 AG News 有更多文章，但 NYT 训练集包含约 597 万次英文词出现，AG News 约 345 万次；两组语料在内容、篇幅和用词上不同。NYT 词向量直接学习目标数据中的词语关系，因此可能更适合当前分类任务。

词向量能否表示测试文章中的词，也是影响效果的因素。我们分别统计词出现次数层面的未登录词比例（token OOV），以及不同词类型层面的未登录词比例（type OOV）：

$$OOV_{\text{token}} = \frac{\sum_{i=1}^{|T|} \mathbf{1}[t_i \notin E]}{|T|}, \quad (7)$$

$$OOV_{\text{type}} = \frac{\sum_{w \in U} \mathbf{1}[w \notin E]}{|U|}. \quad (8)$$

其中 T 为测试集所有词的序列， U 为其中不重复的词集合， E 为词向量词表。

表 4 与图 3 呈现了一个有意思的现象。GloVe 的 token OOV 仅为 0.20%，比 NYT Word2Vec 的 0.71% 更低，但分类结果反而略差。较广的词汇覆盖使模型能够表示更多单词，却不保证这些表示更适合区分当前的新闻主题。训练语料与目标任务的关联，以及词向量平均后保留了多少主题信息，同样值得考虑。

4.3 BERT 的训练过程

图 4 展示了 BERT 的训练过程。训练损失从第一轮 0.2236 降至第三轮的 0.0188，验证损失却从 0.1098 升至 0.1223。验证 Macro-F1 分别为 94.02%、94.78% 和 94.34%，第二轮达到最高，最终测试采用这一轮的模型。训练损失持

续下降而验证性能没有同步提高，说明最后一轮已经出现一定的过拟合迹象。

BERT 最终准确率为 98.35%，Macro-F1 为 96.27%，比二值词袋分别低 0.69 和 1.37 个百分点。其输入长度只有 64 个 WordPiece 位置，而测试新闻按英文词统计的中位长度约为 697 词。两者分词单位不同，但足以看出 BERT 只能利用全文的一小部分。因此，这个结果既反映了模型表现，也受到输入长度限制，不能简单理解为上下文建模不如词袋方法。

5 错误分析

5.1 类别之间的混淆

图 5 显示，所有方法都能非常准确地识别体育新闻，区别主要来自商业和政治类。表 5 中，体育类 F1 始终超过 99.5%，而商业与政治类通常在 92% 至 97% 之间。两类新闻常同时包含政策、经济和社会议题，因此边界更容易混淆。

以 BERT 为例，143 篇商业新闻中有 10 篇被预测成政治新闻，145 篇政治新闻中则有 2 篇被预测成商业新闻。它对政治类的召回率达到 97.24%，对商业类为 91.61%。相比之下，NYT Word2Vec 在两个方向上的误判分别为 5 篇和 8 篇。即使最终准确率接近，两种表示也可能形成不同的决策边界。

5.2 关键词与文档信息

图 7 给出了二值词袋模型的代表性特征。company、market 和 billion 与商业类相关，state、washington 和 republican 与政治类相关，players、league 和 football 则清晰地指向体育。词袋模型之所以表现出色，一个重要原因就是这些主题词可以在全文中被直接识别，并分别获得分类权重。

不过，词汇之间的联系也可能造成混淆。例如 mr 同时出现在商业和政治类的高权重词中，它更像一种新闻写作习惯，而不是明确的主题信号。与此不同，平均词向量将整篇文章压缩成一个 100 维向量，普通背景词会与主题词一起参与平均；BERT 虽能结合上下文，却只能处理文章开头的有限内容。三类方法保留的信息不同，因而会在不同新闻上犯错。

5.3 典型错例

表 6 中的错例展示了三种不同困难。第一篇新闻的体育身份主要出现在后文，短输入可能使模型错过关键背景。第二篇在教育、社会与政治议题之间存在交叉。第三篇一开始就谈到信用卡，却同时大量借用篮球赛事作比喻，表明即使主题词已经出现，干扰性的叙述也可能影响判断。

任务	方法	验证 Acc.	验证 Macro-F1	测试 Acc.	测试 Macro-F1	错误数
Task 1	Binary BoW	98.61	96.67	99.05	97.64	11
Task 1	Frequency BoW	98.44	96.33	98.96	97.42	12
Task 2	NYT Word2Vec	97.83	94.99	98.70	96.72	15
Task 2	AG Word2Vec	96.96	93.37	98.00	95.17	23
Task 2	GloVe 100d	97.74	95.00	98.44	96.33	18
Task 3	BERT 微调	97.57	94.78	98.35	96.27	19

表 3: 六种方法在验证集与测试集上的分类性能，单位为百分比。错误数按 1,152 篇测试新闻统计。




图 2: 六种方法的测试准确率和 Macro-F1。为便于比较，横轴只显示分数较高的区间。




图 3: 三种静态词向量的未登录词比例。GloVe 在两种统计方式下的覆盖率都是最高的。

方法	token 数	占比	type 数	占比
NYT W2V	5,385	0.71%	3,809	14.07%
AG W2V	20,082	2.63%	8,442	31.17%
GloVe	1,530	0.20%	807	2.98%

表 4: 三种词向量在 NYT 测试集上的未登录词统计。测试集共包含 763,200 次词出现和 27,080 个不同词。

方法	商业 F1	政治 F1	体育 F1
Binary BoW	96.48	96.55	99.88
Frequency BoW	95.89	96.48	99.88
NYT Word2Vec	94.81	95.47	99.88
AG Word2Vec	92.47	93.33	99.71
GloVe	94.44	94.85	99.71
BERT	94.58	94.63	99.60

表 5: 各类别在测试集上的 F1，单位为百分比。

图 8 进一步比较各方法出错的文章是否相同。二值词袋只有 11 个错例，其中与 BERT 重合的有 6 个；BERT 共错 19 篇。两种方法在部分新闻上具有互补性，也说明单看总准确率无法完整描述它们的差别。

6 讨论

6.1 简单模型为何表现突出

这组实验中，二值词袋的效果最好，首先与任务本身有关。NYT 新闻篇幅较长，类别又相对




图 4: BERT 在三个训练轮次中的损失与验证集表现。验证 Macro-F1 在第 2 轮达到最高。




图 5: 六种方法的测试集混淆矩阵。每个单元格上方为样本数，下方为该真实类别中的比例。Bus.、Pol. 和 Spo. 分别代表商业、政治和体育。

明确，全文中通常包含多次出现的主题词。词袋模型保留每个词的独立特征，让逻辑回归直接学习其类别关联；二值化还避免将同一关键词的多次出现简单等同于多倍证据。对这一任务而言，这种朴素的表示已经十分有效。

静态词向量的优势是把含义相近的词联系起来，但平均池化会削弱一些关键词的独立作用。BERT 可以捕捉更丰富的上下文，却在本实验中只能读取文章开头。三者比较的不只是模型结构，也包括不同的信息保留方式。若让全部方法处理相同长度的文本，结果可能会改变，

这可以作为后续实验方向。

6.2 实验的适用范围

本实验使用一次固定划分，尚未通过多个随机种子检验方法排名是否稳定。此外，数据检查发现 NYT 中有 72 条重复正文记录，训练集与测试集之间有 10 篇正文完全相同。这种重叠可能使测试性能偏高。当前报告保留原始作业的划分与结果，后续若需更严格地评估泛化能力，应先按正文去重并重新训练。不同方法的分词规则和输入长度也并不完全一致，因此这里的性能对比描述的是既定实验配置，而非模




图 6: 六种方法的错误方向与各类别 F1。左图统计真实类别到预测类别的误判数量，右图比较各类别表现。




图 7: 二值词袋分类器在三个类别上权重较高的词，权重越大表示该词越有利于相应类别的判断。

真实类别 → 预测类别	新闻内容	相关主题线索	可能的混淆原因
体育 → 政治	Ralph Wenzel 在机场跌倒，报道首先讨论其健康与照护处境。	后文交代他曾是一名 NFL 球员，并涉及执教经历。	体育背景出现较晚。
政治 → 商业	波士顿马拉松爆炸案后，报道讨论国际学生与大学的安全问题。	文章涉及招生、教育选择和校园环境。	教育政策与学校经营主题交织。
商业 → 体育	一篇旅行信用卡报道借 NCAA 篮球锦标赛和办公室竞猜展开叙述。	正文讨论 American Express、年费与机场休息室权益。	体育类比干扰商业主题判断。

表 6: BERT 的三个代表性错误样本。文章内容经概括，类别与预测来自原始实验记录。

型能力的绝对排序。

7 结论

在 NYT 新闻分类任务上，二值词袋以 99.05% 的准确率和 97.64% 的 Macro-F1 取得最好结果，词频词袋的表现与之接近。目标语料训练的 Word2Vec 优于外部新闻语料版本；GloVe 的词汇覆盖率最高，却没有得到最高的分类分数。BERT 的表现接近静态词向量，但受到较短输入长度的限制。

更重要的是，六种方法在体育类上都非常准

确，实际差异集中在商业与政治新闻之间。实验说明，文本表示是否有效，要同时看任务中最有用的信息是什么，以及模型能够保留和利用多少这类信息。对于主题清晰的长新闻，简单的词汇表示依然具有很强的竞争力。

References

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. [BERT: Pre-training of deep bidirectional transformers for language understanding](#). In *Proceedings of the 2019 Conference of the North American Chapter of the Association for*

Shared errors on the same test documents

Bin.	11	7	8	11	9	6
Freq.	7	12	9	9	8	3
NYT	8	9	15	12	11	4
AG	11	9	12	23	16	7
GloVe	9	8	11	16	18	7
BERT	6	3	4	7	7	19
	Bin.	Freq.	NYT	AG	GloVe	BERT

图 8: 六种方法两两共同预测错误的文章数量。对角线为各方法的错误总数。

Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), pages 4171–4186. Association for Computational Linguistics.

Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. 2013. [Efficient estimation of word representations in vector space](#). *arXiv preprint arXiv:1301.3781*.

Jeffrey Pennington, Richard Socher, and Christopher Manning. 2014. [GloVe: Global vectors for word representation](#). In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 1532–1543. Association for Computational Linguistics.

Sida Wang and Christopher Manning. 2012. [Baselines and bigrams: Simple, good sentiment and topic classification](#). In *Proceedings of the 50th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pages 90–94. Association for Computational Linguistics.